UNIVERSIDAD DE MEDELLÍN
Facultad de Ingenierías · Estadística para Ingeniería

Teorema del Límite Central y Simulación de Monte Carlo

Una demostración por simulación con Python

INTEGRANTES

Juan Manuel Moreno Muñoz
David Restrepo
Juan Fernando

PROFESOR

Horacio Fernández C.

Contenido: demostración del TLC con seis distribuciones · réplica exacta de la guía · Monte Carlo con los 40 datos · solución de los puntos a–f · tres hallazgos en el archivo Excel · conexión matemática entre los dos temas · aplicación interactiva en Python.

Medellín, octubre de 2026

Contenido

1 Introducción **2**
1.1 Objetivos . . . 2
1.2 ¿Qué significa *demostrar* en este trabajo? . . . 2
1.3 Herramientas: equivalencia entre Excel y Python . . . 2

2 Teorema del Límite Central **3**
2.1 Conceptos previos . . . 3
2.2 Enunciado del teorema . . . 3
2.3 Qué se va a verificar . . . 4
2.4 Metodología: el mismo procedimiento de la guía . . . 4
2.5 Ejemplo resuelto a mano . . . 5
2.6 Resultados: réplica exacta de la guía . . . 6
2.7 Extensión: otras distribuciones vistas en clase . . . 6

3 Simulación de Monte Carlo **9**
3.1 Definición y lógica del método . . . 9
3.2 Los datos y la estimación de parámetros . . . 10
3.3 El modelo y su solución teórica . . . 10
3.4 Una iteración, paso a paso . . . 10
3.5 Implementación en Python . . . 11
3.6 Solución del ejercicio propuesto de la guía . . . 11
3.7 Convergencia: ¿cuántas iteraciones se necesitan? . . . 14
3.8 Hallazgos en el archivo Excel de la guía . . . 15

4 Conexión entre los dos temas: por qué funciona Monte Carlo **17**

5 La aplicación interactiva **18**

6 Conclusiones generales **20**

Referencias **20**

Cómo leer este documento

Cada tema sigue el mismo orden: **(1)** la teoría, con definiciones y teoremas; **(2)** un ejemplo resuelto a mano, con números; **(3)** cómo se hizo la simulación en Excel y su equivalente en Python; **(4)** los resultados, comparando siempre *lo que dice la teoría* contra *lo que salió en la simulación*. Todos los números de este informe fueron calculados por el programa (`scripts/generar_figuras.py`) con semillas fijas, de modo que cualquiera puede volver a ejecutarlo y obtener exactamente los mismos valores.

1. Introducción

1.1 Objetivos

Objetivo general. Demostrar, mediante simulación computacional, el Teorema del Límite Central y el funcionamiento de la Simulación de Monte Carlo, siguiendo las guías del curso y ampliándolas con programación en Python.

Objetivos específicos.

1. Replicar exactamente el procedimiento de la guía del TLC (Poisson con $\lambda = 4$, 200 muestras, $n = 5$ y $n = 30$).
2. Extender el experimento a otras distribuciones vistas en clase, como invita la guía.
3. Construir la simulación de Monte Carlo del costo con los 40 datos y resolver los puntos (a) a (f).
4. Revisar críticamente los supuestos del modelo y del archivo Excel.
5. Mostrar que los dos temas están conectados: el TLC explica por qué Monte Carlo funciona.

1.2 ¿Qué significa *demostrar* en este trabajo?

Existen dos formas de mostrar que un resultado estadístico es cierto:

- **Demostración analítica:** una prueba matemática formal (para el TLC se usan funciones generatrices de momentos o funciones características).
- **Demostración por simulación:** se generan miles de datos aleatorios en el computador y se *verifica con números* que lo que predice la teoría efectivamente ocurre.

Las guías del curso usan el segundo enfoque con Excel. Este trabajo hace **exactamente el mismo procedimiento**, pero en Python, lo que permite repetirlo 10 000 veces en menos de un segundo, con cualquier distribución y comparando automáticamente cada resultado con su valor teórico. Además, en los puntos donde es corto y útil, se incluye también la demostración analítica.

1.3 Herramientas: equivalencia entre Excel y Python

Qué se hace	Excel (guías del profesor)	Python (este trabajo)
Número aleatorio entre 0 y 1	`=ALEATORIO()`	`rng.random()`
Muestras Poisson ($\lambda = 4$)	Análisis de datos → Generación de números aleatorios	`rng.poisson(4, size=(200, n))`
Media de cada muestra	`=PROMEDIO(A2:E2)`	`muestras.mean(axis=1)`
Desviación estándar muestral	`=DESVEST.M(B2:B41)`	`np.std(x, ddof=1)`
Transformada inversa normal	`=INV.NORM(F2;μ;σ)`	`stats.norm.ppf(U, μ, σ)`
Percentil 95	`=PERCENTIL.INC(rango;0,95)`	`np.percentile(costos, 95)`
Recalcular	Tecla F9	Cambiar la semilla / botón “Nueva simulación”
Histograma	Análisis de datos → Histograma	Matplotlib / Plotly

Tabla 1. Cada paso de las guías tiene un equivalente directo en el código.

Librerías utilizadas: **NumPy** (números aleatorios y cálculo), **SciPy** (distribuciones de probabilidad), **Pandas** (tablas), **Matplotlib** y **Plotly** (gráficas) y **Streamlit** (aplicación web interactiva, sección 5).

2. Teorema del Límite Central

2.1 Conceptos previos

Definición 2.1: Muestra aleatoria

Las variables $X_1, X_2, \dots, X_n$ forman una **muestra aleatoria** de tamaño n si son **independientes** y todas tienen **la misma distribución** (se dice que son i.i.d.), con media $\mu = \mathrm{E}[X_i]$ y varianza $\sigma^2 = \mathrm{Var}(X_i)$.

Definición 2.2: Media muestral y distribución muestral

La **media muestral** es

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i = \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

Como cada muestra produce un valor distinto de $\bar{X}$, la media muestral es a su vez una variable aleatoria. Su distribución de probabilidad se llama **distribución muestral de** $\bar{X}$.

La primera pregunta es: ¿dónde está centrada $\bar{X}$ y qué tan dispersa es? La respuesta es exacta y vale para *cualquier* distribución:

Proposición 2.3: Media y varianza de la media muestral

Si $X_1, \dots, X_n$ es una muestra aleatoria con media μ y varianza σ^2, entonces

$$\mathrm{E}[\bar{X}] = \mu \qquad \text{y} \qquad \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n} \quad \Longrightarrow \quad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}.$$

Prueba. Por linealidad de la esperanza: $\mathrm{E}[\bar{X}] = \frac{1}{n}\sum_{i=1}^{n}\mathrm{E}[X_i] = \frac{1}{n}(n\mu) = \mu$. Como las X_i son independientes, la varianza de la suma es la suma de las varianzas, y $\mathrm{Var}(aY) = a^2\mathrm{Var}(Y)$:

$$\mathrm{Var}(\bar{X}) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}. \qquad \square$$

La cantidad $\sigma/\sqrt{n}$ se llama **error estándar** de la media. La proposición dice dónde se centra $\bar{X}$ y cuánto se dispersa, pero **no dice qué forma tiene** su distribución. Eso es lo que aporta el TLC.

2.2 Enunciado del teorema

Teorema 2.4: Teorema del Límite Central (TLC)

Sea $X_1, \dots, X_n$ una muestra aleatoria de **cualquier** distribución con media μ y varianza σ^2 finita.

Entonces la variable estandarizada

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

tiende a la distribución normal estándar $N(0,1)$ cuando $n \to \infty$. En la práctica, para n grande:

$$\boxed{\bar{X} \overset{\text{aprox.}}{\sim} N\left(\mu,\ \frac{\sigma}{\sqrt{n}}\right)}$$

Lo sorprendente del teorema es la palabra **cualquier**: la población puede ser discreta, plana o muy asimétrica, y aun así las medias se distribuyen como una campana. La regla práctica habitual es que $n \geq 30$ es suficiente; si la población ya es simétrica, basta con mucho menos. La siguiente proposición explica por qué las poblaciones asimétricas necesitan n más grande.

Proposición 2.5: La asimetría de $\bar{X}$ disminuye como $1/\sqrt{n}$

Si X tiene coeficiente de asimetría $\gamma = \mathrm{E}[(X-\mu)^3]/\sigma^3$, entonces la media muestral tiene coeficiente de asimetría

$$\gamma_{\bar{X}} = \frac{\gamma}{\sqrt{n}}.$$

Prueba. Sea $S = X_1 + \cdots + X_n$. Para variables independientes, los terceros momentos centrales se suman (igual que las varianzas): $\mathrm{E}[(S-n\mu)^3] = n\,\mathrm{E}[(X-\mu)^3] = n\gamma\sigma^3$, y además $\mathrm{Var}(S) = n\sigma^2$. Como la asimetría no cambia al dividir por n:

$$\gamma_{\bar{X}} = \gamma_S = \frac{n\gamma\sigma^3}{(n\sigma^2)^{3/2}} = \frac{n\gamma\sigma^3}{n^{3/2}\sigma^3} = \frac{\gamma}{\sqrt{n}}. \qquad \square$$

Como la normal tiene asimetría 0, esta proposición muestra cuantitativamente cómo $\bar{X}$ "se va volviendo normal". Por ejemplo, la exponencial tiene $\gamma = 2$: con $n = 30$ la asimetría de las medias ya es sólo $2/\sqrt{30} = 0.365$.

2.3 Qué se va a verificar

El TLC (junto con las proposiciones anteriores) hace **tres predicciones** que la simulación debe confirmar:

Predicción	Qué significa	Cómo se verifica
① **Centro**	El promedio de todas las medias es μ.	Comparar con μ
② **Dispersión**	La desviación estándar de las medias es $\sigma/\sqrt{n}$.	Comparar con $\sigma/\sqrt{n}$
③ **Forma**	Las medias forman una campana normal.	Histograma, asimetría $\gamma/\sqrt{n}$, regla 68–95, gráfico Q-Q

Regla empírica. Si $\bar{X}$ es normal, el 68.27 % de las medias debe quedar a menos de $1\,\sigma_{\bar{X}}$ de μ, y el 95.45 % a menos de $2\,\sigma_{\bar{X}}$. Es una prueba sencilla e intuitiva de normalidad que se usa en las tablas de resultados.

2.4 Metodología: el mismo procedimiento de la guía

El algoritmo es idéntico al de la guía en Excel:

Paso 1. Generar una tabla de R filas por n columnas con números de la distribución elegida (en la guía: $R = 200$ filas, $n = 5$ columnas, celdas `A2:E201`).

Paso 2. Calcular la media de cada fila (columna `F`: `=PROMEDIO(A2:E2)`).

Paso 3. Calcular la media y la desviación estándar de esas R medias (`G2` y `H2`).

Paso 4. Construir el histograma de las medias y compararlo con la curva $N(\mu, \sigma/\sqrt{n})$.

Importante: hay dos números distintos que no se deben confundir. El **tamaño de muestra** n es cuántos datos se promedian (las columnas); el teorema habla de él. El **número de repeticiones** R es cuántas muestras se toman (las filas); sólo sirve para *ver* la distribución con más nitidez. La guía usa $R = 200$; en la extensión se usa $R = 10\,000$ para que las cifras sean más precisas.

Listing 1. Núcleo de la simulación del TLC (archivo `src/tlc.py`).

```python
import numpy as np

rng = np.random.default_rng(2026)          # generador con semilla fija (reproducible)
muestras = rng.poisson(4, size=(200, 5))   # tabla A2:E201 de la guía (200 filas x 5 columnas)
medias = muestras.mean(axis=1)             # columna F: =PROMEDIO(A2:E2) en cada fila

print(medias.mean())                       # celda G2: =PROMEDIO(F2:F201)   -> teoría: 4
print(medias.std(ddof=1))                  # celda H2: =DESVEST(F2:F201)    -> teoría: 2/raíz(5)
```

2.5 Ejemplo resuelto a mano

Ejemplo 2.6: Poisson con $\lambda = 4$ (la distribución de la guía)

Parámetros de la población. En una distribución de Poisson la media y la varianza son iguales a λ:

$$\mu = \lambda = 4, \qquad \sigma = \sqrt{\lambda} = \sqrt{4} = 2, \qquad \gamma = \frac{1}{\sqrt{\lambda}} = 0.5.$$

Una muestra de tamaño $n = 5$. La primera fila que generó el programa fue $(4,\ 7,\ 5,\ 4,\ 4)$. Su media es

$$\bar{x}_1 = \frac{24}{5} = 4.8.$$

Predicciones del TLC para las 200 medias:

$$n = 5: \quad \mathrm{E}[\bar{X}] = 4, \quad \sigma_{\bar{X}} = \frac{2}{\sqrt{5}} = 0.8944, \quad \gamma_{\bar{X}} = \frac{0.5}{\sqrt{5}} = 0.224$$

$$n = 30: \quad \mathrm{E}[\bar{X}] = 4, \quad \sigma_{\bar{X}} = \frac{2}{\sqrt{30}} = 0.3651, \quad \gamma_{\bar{X}} = \frac{0.5}{\sqrt{30}} = 0.091$$

Es decir: al pasar de $n = 5$ a $n = 30$ las medias siguen centradas en 4, pero se concentran $\sqrt{30/5} = 2.45$ veces más y se vuelven más simétricas.

2.6 Resultados: réplica exacta de la guía

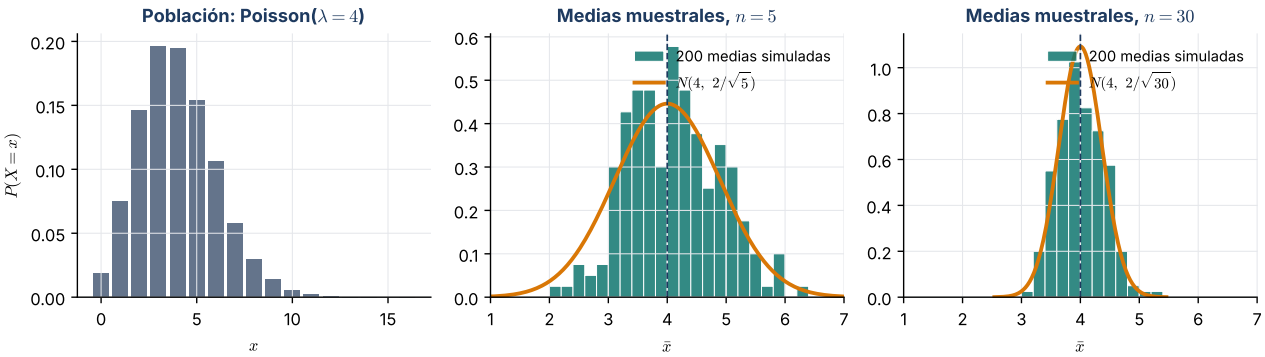


Figura 1. Réplica de la guía: población Poisson(4) (izquierda) e histogramas de las 200 medias con $n = 5$ y $n = 30$, con clases de ancho 0.2 entre 1.0 y 7.0 como en la columna *Bin*. La curva naranja es la normal que predice el TLC.

		$n = 5$		$n = 30$	
Celda de la guía	Fórmula	Teoría	Simulación	Teoría	Simulación
`G2` (media de las medias)	`=PROMEDIO(F2:F201)`	4	4.0250	4	3.9830
`H2` (desv. de las medias)	`=DESVEST(F2:F201)`	0.8944	0.8122	0.3651	0.3889
% dentro de $\mu \pm 2\sigma_{\bar{X}}$	—	95.45	96.0	95.45	94.5

Tabla 2. Teoría contra simulación en la réplica de la guía (200 muestras).

Lectura. Las medias quedan centradas en 4 y su dispersión baja de ≈ 0.89 a ≈ 0.37 al pasar de $n = 5$ a $n = 30$, como predice $\sigma/\sqrt{n}$. Las diferencias en la segunda o tercera cifra son normales: con sólo 200 repeticiones la propia desviación estándar tiene un error relativo de aproximadamente $1/\sqrt{2(R-1)} = 1/\sqrt{398} \approx 5\,\%$. Por eso, para la extensión se usan 10 000 repeticiones.

2.7 Extensión: otras distribuciones vistas en clase

La guía invita a "hacer el ejercicio con más distribuciones y más observaciones". Se eligieron cuatro poblaciones muy distintas entre sí, incluyendo dos **muy asimétricas** (exponencial y geométrica), que son la prueba más difícil para el teorema.

Distribución	Uso típico	μ	σ	Asimetría γ
Exponencial($\beta = 2$)	Tiempo entre fallas, tiempo de respuesta	$\beta = 2$	$\beta = 2$	2
Geométrica($p = 0.25$)	Ensayos hasta el primer éxito	$1/p = 4$	$\sqrt{1-p}/p = 3.464$	2.021
Binomial($m = 10,\ p = 0.2$)	Defectuosos en un lote de 10	$mp = 2$	$\sqrt{mp(1-p)} = 1.265$	0.474
Dado (uniforme 1–6)	Población plana	3.5	$\sqrt{35/12} = 1.708$	0

Tabla 3. Parámetros teóricos de las poblaciones usadas.

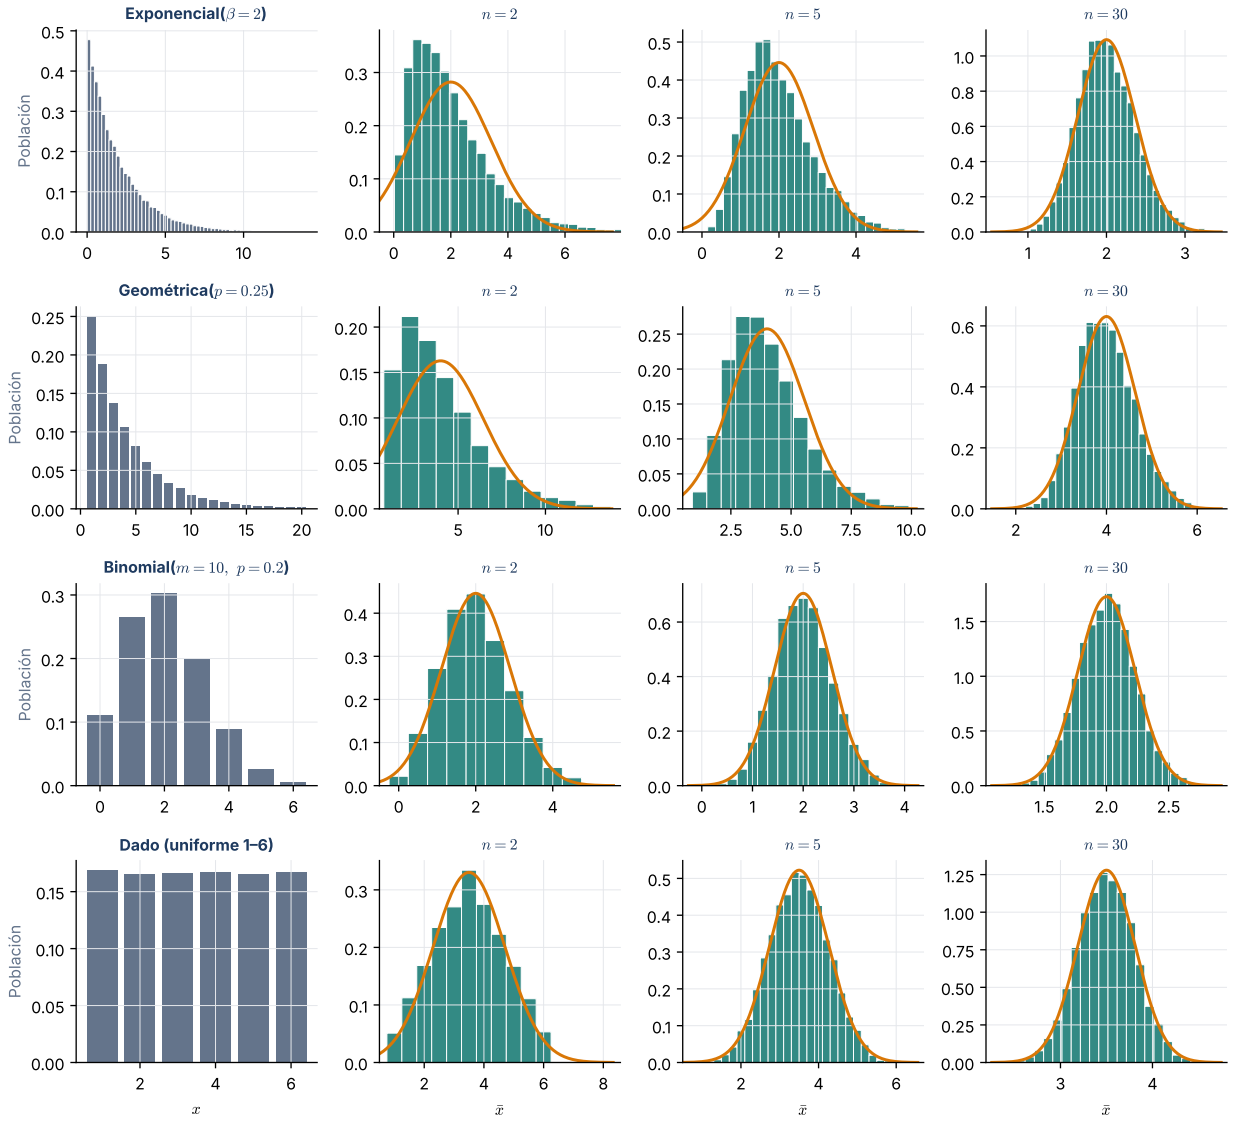


Figura 2. Cada fila es una población (columna izquierda, en gris) y el histograma de 10 000 medias para $n = 2$, 5 y 30. Con $n = 2$ las poblaciones asimétricas todavía "heredan" su cola derecha; con $n = 30$ las cuatro coinciden con la curva normal.

		① Centro		② Dispersión		③ Asimetría		③ Regla empírica (%)	
Población	n	μ	obs.	$\sigma/\sqrt{n}$	obs.	$\gamma/\sqrt{n}$	obs.	$\pm1\sigma_{\bar{X}}$ (68.27)	$\pm2\sigma_{\bar{X}}$ (95.45)
Exponencial	1	2.000	2.005	2.000	1.980	2.000	1.840	86.2	95.0
	5	2.000	1.984	0.894	0.888	0.894	0.862	69.7	96.2
	30	2.000	1.997	0.365	0.370	0.365	0.362	67.7	95.6
Geométrica	1	4.000	3.986	3.464	3.425	2.021	1.996	86.7	94.6
	5	4.000	4.004	1.549	1.531	0.904	0.880	68.9	95.8
	30	4.000	4.006	0.632	0.635	0.369	0.380	67.1	95.5
Binomial	1	2.000	2.007	1.265	1.260	0.474	0.460	77.3	96.7
	5	2.000	2.010	0.566	0.562	0.212	0.228	63.1	95.0
	30	2.000	1.998	0.231	0.232	0.087	0.088	65.1	95.0
Dado	1	3.500	3.496	1.708	1.689	0.000	-0.004	67.8	100.0
	5	3.500	3.488	0.764	0.757	0.000	-0.018	69.5	97.1
	30	3.500	3.502	0.312	0.314	0.000	0.018	68.4	95.2

Tabla 4. Teoría contra simulación (10 000 repeticiones por fila). "obs." = valor observado.

Cómo leer la tabla. En las cuatro poblaciones y para todo n, las columnas de centro y dispersión coinciden con la teoría hasta la segunda cifra decimal: esto confirma la Proposición 2.3. La forma es la parte interesante: con $n = 1$ (la población misma) la exponencial tiene asimetría ≈ 2 y el 86 % de los datos dentro de $\pm1\sigma$ (una normal tendría 68.27 %), así que *no* es normal. Con $n = 30$ la asimetría bajó a ≈ 0.36, como predice $2/\sqrt{30}$, y los porcentajes ya son ≈ 68 % y ≈ 95.5 %, los de una normal.

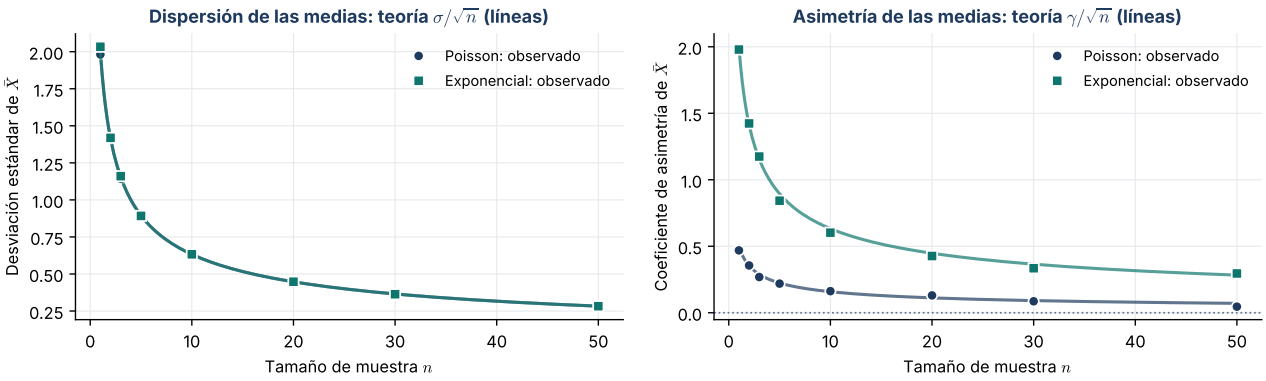


Figura 3. Puntos: valores observados en la simulación. Líneas: teoría. Izquierda: la dispersión de las medias sigue exactamente $\sigma/\sqrt{n}$. Derecha: la asimetría sigue $\gamma/\sqrt{n}$ y tiende a 0, el valor de la normal.

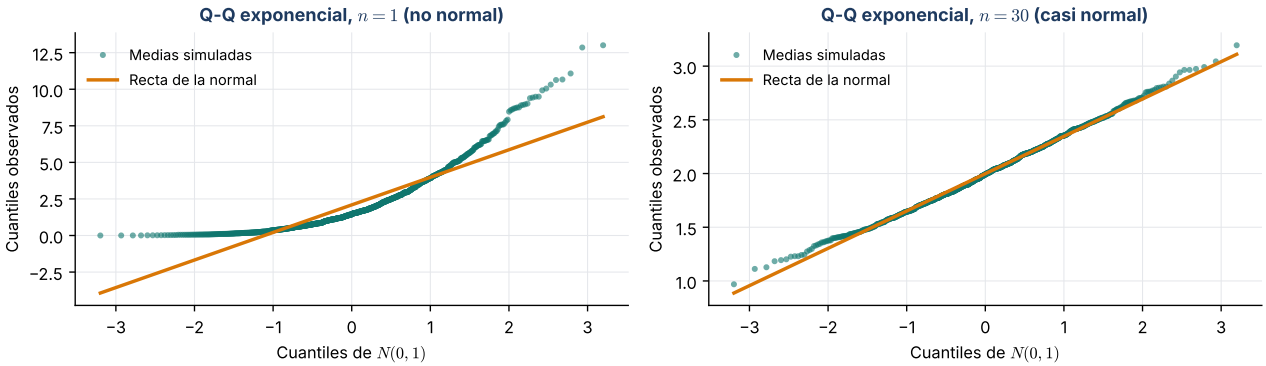


Figura 4. Gráficos Q-Q para la exponencial. Si los datos son normales, los puntos caen sobre la recta. Con $n = 1$ se curvan (población asimétrica); con $n = 30$ quedan alineados.

Conclusión del TLC

Las tres predicciones se cumplieron en todas las poblaciones: **(1)** las medias se centran en μ; **(2)** su desviación estándar es $\sigma/\sqrt{n}$; **(3)** su forma se vuelve normal, con una asimetría que desaparece como $\gamma/\sqrt{n}$. Para poblaciones simétricas (dado) la campana aparece desde $n \approx 5$; para poblaciones muy asimétricas (exponencial, geométrica) se necesita $n \approx 30$, que es justamente el origen de la regla práctica que se usa en clase.

3. Simulación de Monte Carlo

3.1 Definición y lógica del método

Definición 3.1: Simulación de Monte Carlo

Técnica que estudia un problema con incertidumbre generando **muchos escenarios aleatorios**, calculando el resultado en cada uno y analizando la **distribución** de todos esos resultados (promedio, desviación, percentiles, probabilidades), en lugar de trabajar con un único valor promedio.

El procedimiento de la guía tiene cinco pasos: **(1)** definir la variable incierta (la demanda); **(2)** elegir su distribución (normal); **(3)** generar números aleatorios uniformes; **(4)** transformarlos en demandas con la distribución elegida; **(5)** calcular el costo y repetir muchas veces. El paso clave es el (4), que se justifica con el siguiente teorema.

Teorema 3.2: Método de la transformada inversa

Sea F una función de distribución acumulada continua y estrictamente creciente, y sea $U \sim \text{Uniforme}(0,1)$. Entonces la variable

$$X = F^{-1}(U)$$

tiene exactamente la distribución F.

Prueba. Como F es creciente, $F^{-1}(U) \le x$ ocurre si y sólo si $U \le F(x)$. Y para una uniforme en $(0,1)$, $P(U \le u) = u$. Por lo tanto

$$P(X \le x) = P(F^{-1}(U) \le x) = P(U \le F(x)) = F(x). \qquad \square$$

Esto es exactamente lo que hace Excel con `=INV.NORM(ALEATORIO();μ;σ)`: `ALEATORIO()` da U e `INV.NORM` aplica F^{-1} de la normal.

3.2 Los datos y la estimación de parámetros

Se usan los 40 datos hipotéticos de la hoja "Datos y Simulación" (demanda entre 120 y 180 unidades). Los parámetros se estiman con las fórmulas de la guía:

$$\hat{\mu}_D = \bar{x} = \frac{1}{40}\sum_{i=1}^{40} x_i = 151.4, \qquad s_D = \sqrt{\frac{1}{39}\sum_{i=1}^{40}(x_i - \bar{x})^2} = 16.0653, \qquad \bar{c} = \frac{1}{40}\sum_{i=1}^{40} c_i = 17.34 \text{ USD}.$$

¿Es razonable suponer que la demanda es normal? La guía recomienda verificar que la distribución sea compatible con los datos. Se aplicó la prueba de Shapiro-Wilk (H_0: los datos provienen de una normal) a las 40 demandas: **valor-p** $= 0.581 > 0.05$, así que no hay evidencia para rechazar la normalidad. El supuesto de la guía es razonable.

3.3 El modelo y su solución teórica

$$\boxed{C = D \times \bar{c}, \qquad D \sim N(\hat{\mu}_D,\ s_D) = N(151.4,\ 16.07), \qquad \bar{c} = 17.34}$$

Este modelo es tan sencillo que se puede resolver también *sin* simular, lo que permite comprobar si la simulación es correcta:

Proposición 3.3: Distribución exacta del costo

Si $D \sim N(\mu_D, \sigma_D)$ y $\bar{c}$ es una constante positiva, entonces $C = \bar{c}\,D \sim N(\bar{c}\,\mu_D,\ \bar{c}\,\sigma_D)$, y su percentil p es $C_p = \bar{c}\,\mu_D + z_p\,\bar{c}\,\sigma_D$.

Ejemplo 3.4: Valores teóricos del costo

$$\mu_C = 17.34 \times 151.4 = 2\,625.3 \text{ USD}, \qquad \sigma_C = 17.34 \times 16.0653 = 278.6 \text{ USD},$$
$$C_{0.95} = 2\,625.3 + 1.645\,(278.6) = 3\,083.5 \text{ USD}, \qquad C_{0.05} = 2\,625.3 - 1.645\,(278.6) = 2\,167.1 \text{ USD}.$$

Estos son los valores contra los que se compara la simulación.

3.4 Una iteración, paso a paso

Ejemplo 3.5: Una iteración con $U = 0.83$

Paso 1.	Número aleatorio uniforme: $U = 0.83$	`=ALEATORIO()`
Paso 2.	Valor z que deja un área de 0.83 a la izquierda: $z = \Phi^{-1}(0.83) = 0.9542$	`=INV.NORM.ESTAND(0,83)`
Paso 3.	Demanda: $D = \mu_D + z\,\sigma_D = 151.4 + (0.9542)(16.07) = 166.73 \approx 167$	`=REDONDEAR(INV.NORM(...);0)`
Paso 4.	Costo: $C = 167 \times 17.34 = 2\,895.78$ USD	`=G2*C2`

Interpretación: la probabilidad de que la demanda sea menor o igual a 166.73 es exactamente 0.83. Éste es *un* escenario posible; la simulación repite este proceso miles de veces.

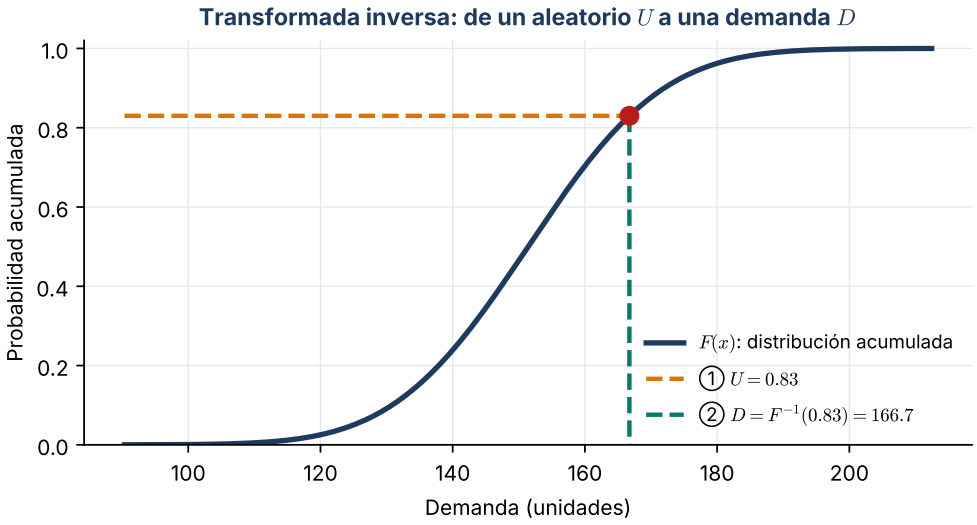


Figura 5. Transformada inversa: el valor $U = 0.83$ (eje vertical) "rebota" en la curva acumulada F y se convierte en la demanda $D = F^{-1}(0.83)$ (eje horizontal).

3.5 Implementación en Python

Listing 2. Núcleo de la simulación de Monte Carlo (archivo `src/montecarlo.py`).

```python
import numpy as np
from scipy import stats

mu, s, c, N = 151.4, 16.0653, 17.34, 10_000
rng = np.random.default_rng(2026)

U = rng.random(N)                                      # =ALEATORIO()
demanda = np.round(stats.norm.ppf(U, loc=mu, scale=s)) # =REDONDEAR(INV.NORM(U; mu; s); 0)
costo = demanda * c                                    # Costo = Demanda x Costo unitario

print(costo.mean(), costo.std(ddof=1))                 # promedio y desviación estándar
print(np.percentile(costo, [5, 50, 95]))               # P5, mediana y P95
```

3.6 Solución del ejercicio propuesto de la guía

(a) Presionar F9 cinco veces y observar los cambios

Se simularon cinco recálculos de la hoja de 40 filas. La tabla muestra el promedio de la demanda simulada (columna `G`) y del costo simulado (columna `H`), con la fórmula **original** del archivo y con la fórmula **corregida** (ver Hallazgo 3.6):

	Fórmula original del Excel		Fórmula corregida	
Recálculo	Demanda prom.	Costo prom. (USD)	Demanda prom.	Costo prom. (USD)
F9 n.º 1	144.1	2 492.9	152.5	2 645.3
F9 n.º 2	142.3	2 461.8	151.1	2 620.4
F9 n.º 3	141.7	2 451.9	150.7	2 613.7
F9 n.º 4	142.6	2 468.7	152.2	2 641.4
F9 n.º 5	144.2	2 493.8	151.5	2 623.2

Tabla 5. Cinco recálculos (F9) de la hoja "Datos y Simulación".

Observación: los valores cambian en cada F9 porque `ALEATORIO()` genera nuevos números. Con sólo 40 escenarios el promedio varía notablemente de un recálculo a otro, y con la fórmula original la demanda promedio queda *siempre* por debajo de la media real de 151.4 unidades.

(b) 1 000 iteraciones: promedio, desviación y percentiles

Medida del costo (USD)	1 000 iteraciones	10 000 iteraciones	Valor teórico
Promedio	2 646.5	2 631.9	2 625.3
Desviación estándar	275.8	277.0	278.6
Percentil 5 %	2 202.2	2 184.8	2 167.1
Percentil 50 % (mediana)	2 653.0	2 635.7	2 625.3
Percentil 95 %	3 086.5	3 086.5	3 083.5
Mínimo / Máximo	1 786.0 / 3 606.7	1 630.0 / 3 710.8	—

Tabla 6. Resultados de la simulación del costo contra los valores teóricos de la Proposición 3.3.

Con 10 000 iteraciones todos los valores quedan a menos del 0.5 % del valor teórico, lo que **confirma que la simulación está bien construida**.

(c) Histograma de los costos simulados

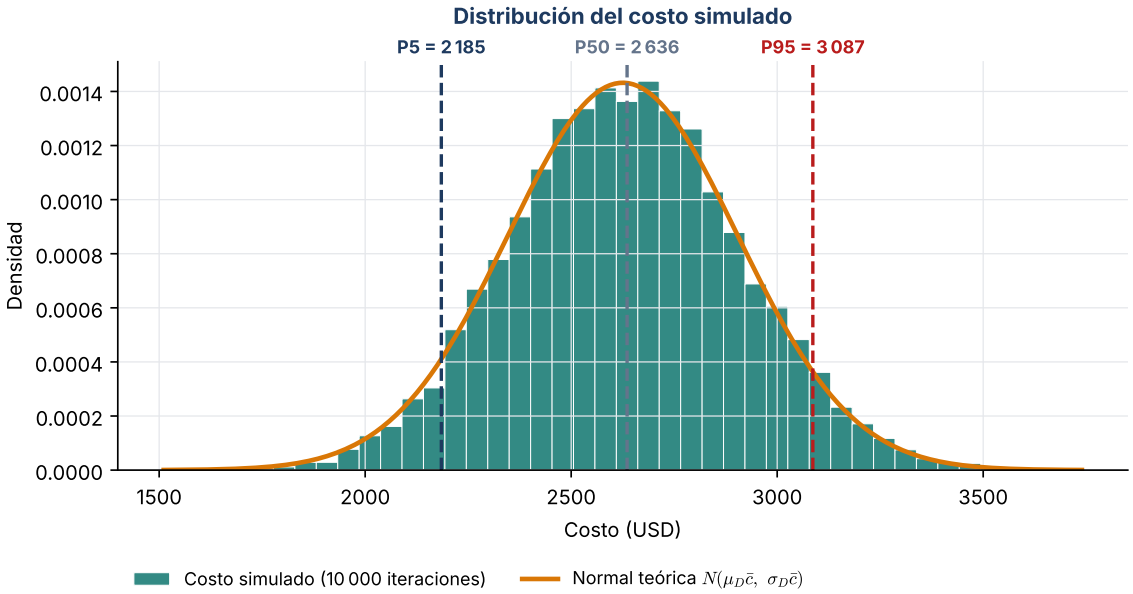


Figura 6. Distribución de 10 000 costos simulados con los percentiles 5, 50 y 95. La curva naranja es la distribución exacta de la Proposición 3.3.

(d) ¿Qué significa el percentil 95 para un gerente de proyecto?

Respuesta

El **95 %** de los escenarios simulados tuvo un costo menor o igual a **USD 3 086.5**. Dicho en términos de riesgo: si el gerente presupuesta esa cifra, bajo este modelo sólo en **1 de cada 20** escenarios el costo real superaría el presupuesto. El escenario central (mediana) es USD 2 635.7; la diferencia entre ambos (≈ USD 450) es una referencia para la **reserva de contingencia**. Como advierte la guía, el P95 no se convierte automáticamente en presupuesto: depende del riesgo que acepte la organización, de los contratos y del juicio técnico.

(e) Efecto de modificar el costo unitario

Costo unitario (USD)	Promedio	Desviación	P5	P50	P95
16.00	2 428.5	255.6	2 016	2 432	2 848
17.00	2 580.3	271.6	2 142	2 584	3 026
17.34	2 631.9	277.0	2 185	2 636	3 087
18.00	2 732.1	287.6	2 268	2 736	3 204
19.00	2 883.9	303.5	2 394	2 888	3 382

Tabla 7. Sensibilidad del costo al costo unitario (10 000 iteraciones, mismos números aleatorios).

Análisis. Como $C = \bar{c}\, D$, el promedio y la desviación son proporcionales a $\bar{c}$:

$$\frac{\partial\, \mathrm{E}[C]}{\partial \bar{c}} = \mu_D = 151.4, \qquad \frac{\partial\, \sigma_C}{\partial \bar{c}} = \sigma_D = 16.07.$$

Es decir, **cada dólar adicional en el costo unitario aumenta el costo esperado en ≈ USD 151 y la desviación en ≈ USD 16**. Un aumento del 10 % en el costo unitario aumenta en 10 % todos los resultados (promedio, percentiles y riesgo).

(f) Supuestos que pueden producir resultados poco realistas

1. **Independencia entre demanda y costo unitario.** Es el supuesto más importante: en los datos la correlación es $r = -0.958$ (Hallazgo 3.8).
2. **Costo unitario fijo.** Se usa el promedio $\bar{c}$ y se ignora su variabilidad.
3. **Normalidad de la demanda.** Es razonable (Shapiro-Wilk, $p = 0.581$); en teoría la normal admite demandas negativas, pero aquí $P(D < 0) = \Phi(-151.4/16.07) = \Phi(-9.42) \approx 10^{-21}$, despreciable.
4. **Sólo 40 datos.** $\hat{\mu}_D$ y s_D son estimaciones con error; la simulación no incluye esa incertidumbre de los parámetros.
5. **Modelo incompleto.** No incluye otras fuentes de costo (mano de obra, tiempo de operación).
6. **Errores en el archivo Excel**, descritos en la sección siguiente.

3.7 Convergencia: ¿cuántas iteraciones se necesitan?

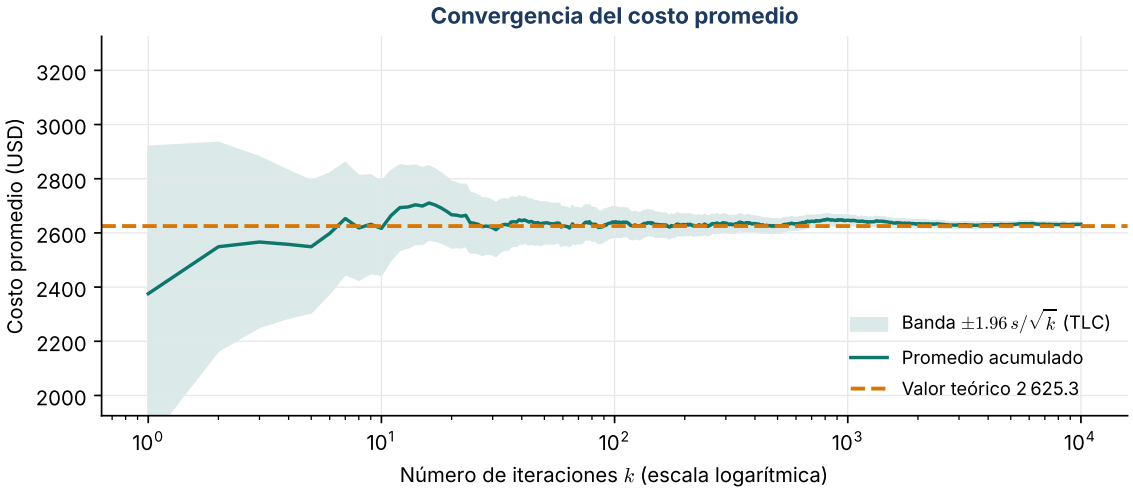


Figura 7. Promedio acumulado del costo después de k iteraciones (escala logarítmica). La banda sombreada es el margen $\pm 1.96\, s/\sqrt{k}$ que predice el TLC (sección 4).

El promedio acumulado fue 2 644.8 con 40 iteraciones, 2 639.3 con 100, 2 646.5 con 1 000 y 2 631.9 con 10 000 (valor teórico: 2 625.3). Con pocas iteraciones el resultado oscila; a partir de unas mil se estabiliza. Esto responde la recomendación de la guía de "usar un número adecuado de iteraciones y comprobar la estabilidad de los resultados".

3.8 Hallazgos en el archivo Excel de la guía

Al revisar las fórmulas del archivo `Simulación_Montecarlo_40_datos.xlsx` se encontraron tres situaciones que afectan los resultados.

Hallazgo 3.6: La demanda simulada tiene un tope oculto

La columna `G` de la hoja "Datos y Simulación" no contiene sólo `INV.NORM`, sino:

```
=REDONDEAR(MIN(B2; MAX(80; REDONDEAR(INV.NORM(F2;μ;σ);0)));0)
```

El `MIN(B2;…)` impide que la demanda simulada supere la demanda *histórica de esa misma fila*. Por ejemplo, en la fila 1 (demanda histórica 120) la simulación nunca puede pasar de 120, aunque la media sea 151.4. La simulación queda **sesgada hacia abajo**: al simular 10 000 veces la tecla F9, el promedio de la columna `G` fue **142.3** en lugar de **151.4** (sesgo de -9.1 unidades, -6.0 %), y ningún recálculo superó 147.7.
Corrección: `=REDONDEAR(INV.NORM(F2;$B$46;DESVEST.M($B$2:$B$41));0)` (el `MAX(80;…)` puede conservarse como piso, porque no introduce sesgo apreciable).

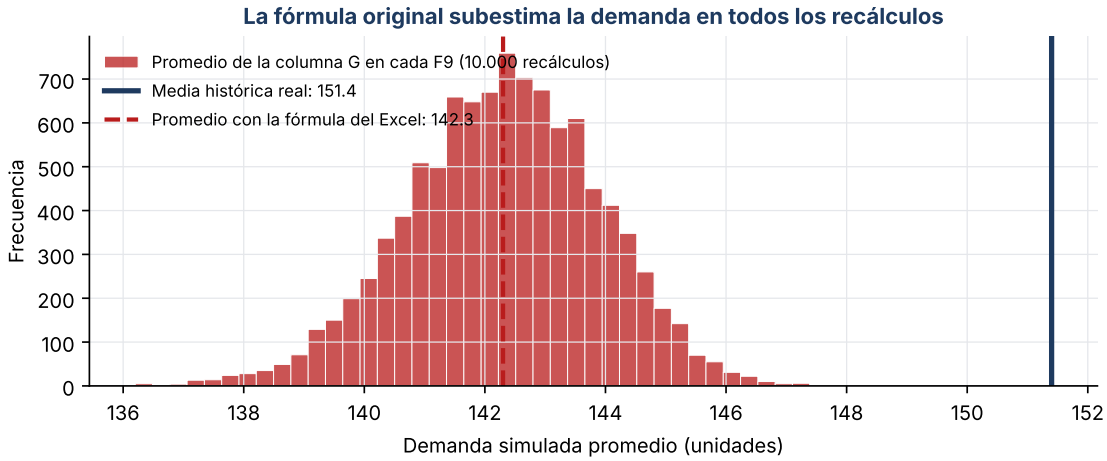


Figura 8. Promedio de la columna G en 10 000 recálculos con la fórmula original: siempre queda lejos de la media histórica.

Hallazgo 3.7: La hoja "Plantilla Monte Carlo" está incompleta

La columna `C` (*Demanda simulada*) de las 1 000 iteraciones está vacía, por lo que el costo simulado (`=C2*D2`) da 0 en todas las filas. **Corrección:** en `C2` escribir

```
=REDONDEAR(INV.NORM(B2;PROMEDIO('Datos y Simulación'!$B$2:$B$41);
        DESVEST.M('Datos y Simulación'!$B$2:$B$41));0)
```

y copiar hasta `C1001`. El programa en Python realiza exactamente este cálculo.

Hallazgo 3.8: La demanda y el costo unitario no son independientes

La correlación entre la demanda y el costo unitario es $r = -0.958$: cuando se compra más, el precio por unidad baja (economía de escala). La recta de regresión es $c = 23.79 - 0.0426\,D$: cada unidad adicional de demanda reduce el costo unitario en unos 4 centavos. El modelo de la guía usa un costo unitario fijo y **ignora esta relación**, aunque la propia guía (sección 11) recomienda "no asumir independencia sin justificación".

Modelo mejorado (normal bivariada). Para respetar la correlación ρ se generan dos normales estándar independientes Z_1 y Z_2 y se combinan así:

$$D = \mu_D + \sigma_D\, Z_1, \qquad c = \mu_c + \sigma_c \left(\rho\, Z_1 + \sqrt{1-\rho^2}\; Z_2\right),$$

con $\mu_c = 17.34$ y $\sigma_c = 0.7153$. Es fácil comprobar que $\mathrm{Var}(c) = \sigma_c^2(\rho^2 + 1 - \rho^2) = \sigma_c^2$ y que $\mathrm{Corr}(D, c) = \rho$. En Excel se implementa con dos columnas de `INV.NORM.ESTAND(ALEATORIO())`.

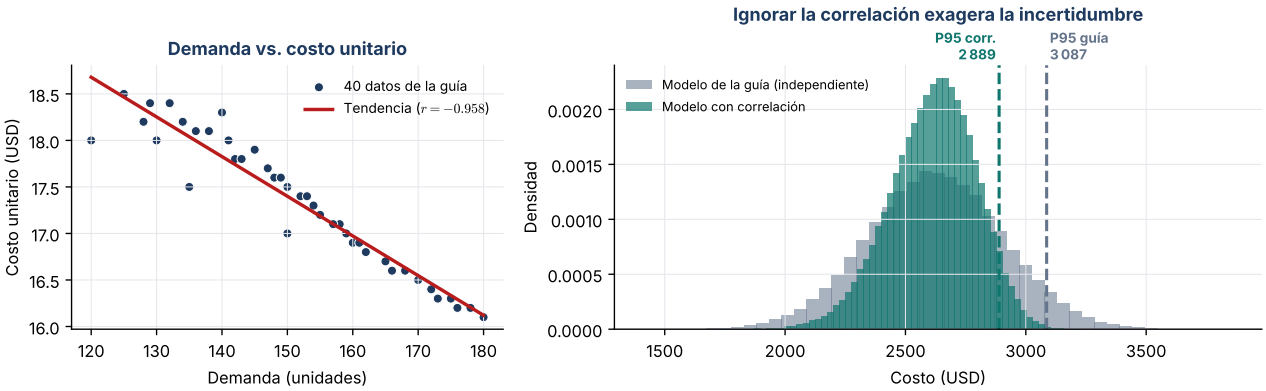


Figura 9. Izquierda: los 40 datos muestran una fuerte relación negativa. Derecha: distribución del costo con 100 000 iteraciones en ambos modelos.

Modelo	Promedio	Desviación	P5	P95
Guía (costo unitario fijo)	2 623.7	278.8	2 167.5	3 086.5
Con correlación (mejorado)	2 614.4	177.9	2 305.7	2 889.1
Datos históricos reales (40)	2 614.5	176.9	—	—

Tabla 8. Comparación de modelos (100 000 iteraciones, USD).

Lectura. Los dos modelos tienen prácticamente el mismo promedio, pero el modelo de la guía **sobrestima la variabilidad en un 58 %**: su desviación (278.8) es mucho mayor que la de los datos reales (176.9), mientras que el modelo con correlación (177.9) la reproduce casi exacta. La razón es intuitiva: cuando la demanda es alta, el costo unitario es bajo, y los dos efectos se compensan parcialmente. En consecuencia, **el P95 de la guía sobrestima el escenario alto en USD 197**, lo que llevaría a reservar más contingencia de la necesaria.

Conclusión de Monte Carlo

La simulación reproduce los valores teóricos con un error menor al 0.5 % y permite responder preguntas de riesgo ("¿con qué probabilidad nos pasamos del presupuesto?") que un único valor promedio no responde. Pero un modelo de Monte Carlo es tan bueno como sus supuestos: corregir el tope de la fórmula y, sobre todo, incluir la correlación cambia el escenario alto en casi 200 dólares.

4. Conexión entre los dos temas: por qué funciona Monte Carlo

El costo promedio que entrega una simulación de N iteraciones es

$$\bar{C}_N = \frac{1}{N}\sum_{k=1}^{N} C_k.$$

Pero $C_1, \ldots, C_N$ son independientes y tienen la misma distribución: $\bar{C}_N$ **es una media muestral**. Por lo tanto, el TLC y la Proposición 2.3 se aplican directamente:

Proposición 4.1: Error de una simulación de Monte Carlo

$$\bar{C}_N \overset{\text{aprox.}}{\sim} N\left(\mu_C,\ \frac{\sigma_C}{\sqrt{N}}\right) \quad\Longrightarrow\quad \text{error típico} = \frac{\sigma_C}{\sqrt{N}}, \qquad \text{margen al } 95\,\% = \pm 1.96\,\frac{\sigma_C}{\sqrt{N}}.$$

Experimento. Para cada N se repitió la simulación completa 500 veces y se midió cuánto varía el costo promedio de una simulación a otra. Con $\sigma_C = 278.6$ USD:

Iteraciones N	Error teórico $\sigma_C/\sqrt{N}$ (USD)	Error observado (USD)
10	88.09	86.71
100	27.86	28.79
1 000	8.81	8.75
10 000	2.79	2.62

Tabla 9. El error de Monte Carlo observado coincide con el que predice el TLC.

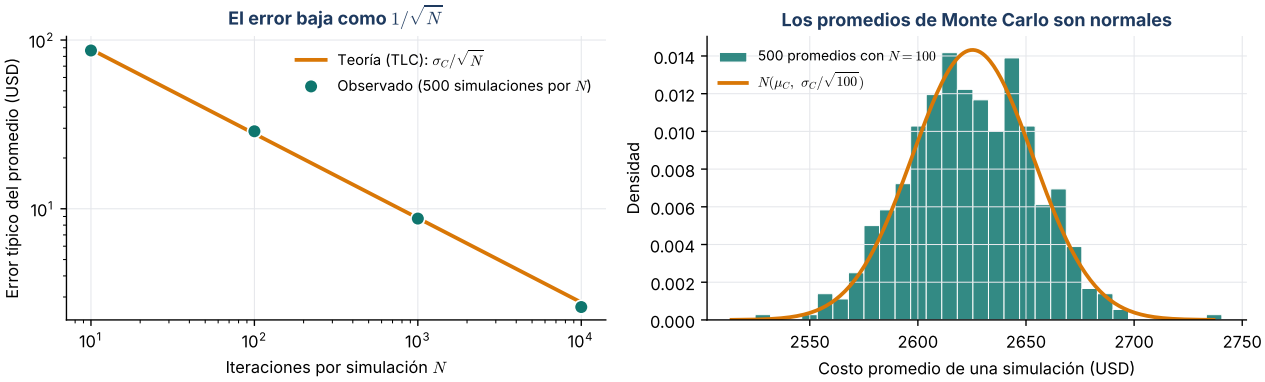


Figura 10. Izquierda: el error baja exactamente como $1/\sqrt{N}$ (en escala log-log es una recta de pendiente $-1/2$). Derecha: los 500 promedios con $N = 100$ forman una campana, como dice el TLC.

Ejemplo 4.2: ¿Cuántas iteraciones se necesitan?

Si se quiere estimar el costo promedio con un margen de ± 5 USD al 95 % de confianza:

$$1.96\,\frac{\sigma_C}{\sqrt{N}} \le 5 \quad\Longrightarrow\quad N \ge \left(\frac{1.96 \times 278.6}{5}\right)^2 = (109.2)^2 \approx 11\,930 \text{ iteraciones.}$$

Por eso las 1 000 iteraciones de la plantilla dan un margen de $\pm 1.96 \times 278.6/\sqrt{1000} \approx \pm 17$ USD.

Regla práctica

Para reducir el error a la mitad hay que **cuadruplicar** las iteraciones; para dividirlo por 10, multiplicarlas por 100. Los dos temas de este trabajo no son independientes: **el Teorema del Límite Central es la garantía matemática de que la Simulación de Monte Carlo funciona**, y además dice cuánto se puede confiar en su resultado.

5. La aplicación interactiva

Además de este informe, se desarrolló una aplicación web en Python (Streamlit) que permite repetir todos los experimentos en vivo: cambiar la distribución, el tamaño de muestra n, el número de iteraciones o el costo unitario, y presionar el botón **"Nueva simulación (F9)"** para generar nuevos números aleatorios. Tiene cinco pestañas:

Pestaña	Qué contiene
Inicio	Qué significa "demostrar por simulación" y la tabla de equivalencias Excel–Python.
Teorema del Límite Central	Laboratorio con seis distribuciones (Poisson, binomial, geométrica, dado, uniforme y exponencial), deslizadores para n y las repeticiones, verificación automática de las tres predicciones, animación de la campana al crecer n, gráficos Q-Q y la réplica exacta de la guía.
Simulación de Monte Carlo	Datos, una iteración paso a paso, simulación de 40 a 100 000 iteraciones, percentiles, convergencia, puntos (d), (e) y (f) y los tres hallazgos del archivo Excel.
Conexión entre los dos temas	Experimento que muestra que el error de Monte Carlo es $\sigma/\sqrt{N}$.
Datos	Los 40 datos, estadísticos descriptivos y descarga de la simulación en CSV.

Cómo ejecutarla (requiere Python 3.10 o superior):

```
pip install -r requirements.txt     # instalar librerías (una sola vez)
streamlit run app.py                # abre la aplicación en el navegador
python scripts/generar_figuras.py   # regenera las figuras y los números de este informe
```

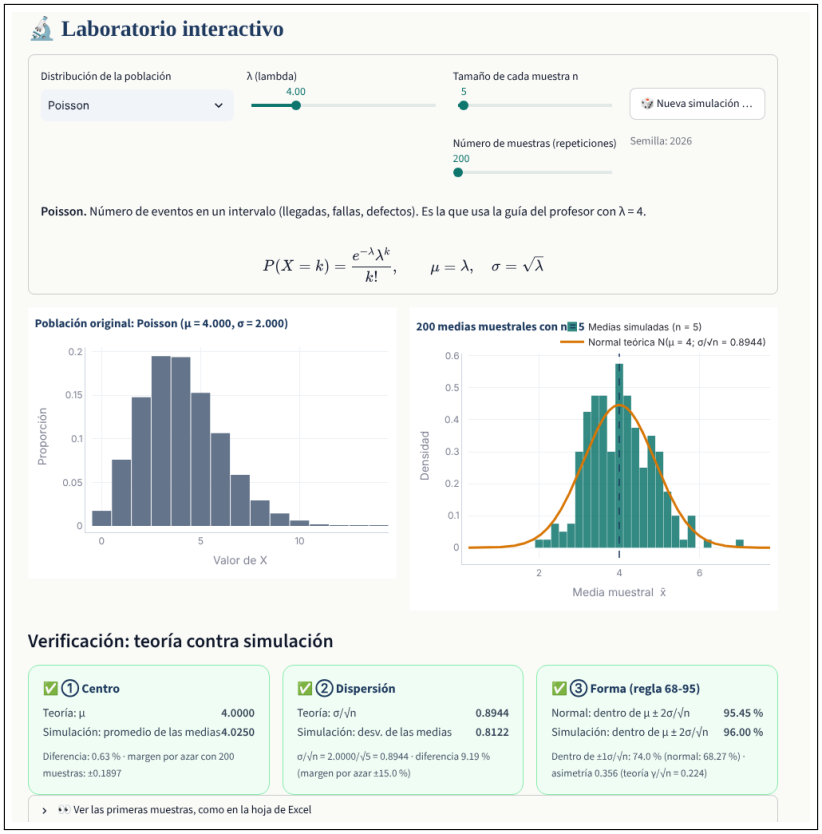


Figura 11. Pestaña del TLC: controles del laboratorio (distribución, n, repeticiones y botón F9), histogramas de la población y de las medias, y tarjetas que comparan automáticamente cada predicción con la simulación.



Figura 12. Pestaña de Monte Carlo: una iteración paso a paso con un deslizador para el número aleatorio U.

6. Conclusiones generales

1. **El TLC quedó demostrado por simulación.** En la réplica de la guía y en cuatro distribuciones adicionales, las medias muestrales se centraron en μ, su desviación fue $\sigma/\sqrt{n}$ y su forma se volvió normal, con una asimetría que cayó como $\gamma/\sqrt{n}$.
2. **El tamaño de muestra necesario depende de la asimetría de la población**: $n \approx 5$ basta para un dado; la exponencial y la geométrica necesitan $n \approx 30$.
3. **La simulación de Monte Carlo reprodujo los valores teóricos** del costo (promedio 2 625.3, P95 3 083.5) con un error menor al 0.5 %, y se resolvieron los puntos (a) a (f) del ejercicio.
4. **La revisión crítica del archivo Excel** encontró un tope en la fórmula de la demanda (sesgo de -6.0 %), una plantilla incompleta y una correlación de -0.958 no considerada; incluirla reduce el P95 en USD 197.
5. **Los dos temas están conectados:** el promedio de una simulación es una media muestral, así que el TLC garantiza que Monte Carlo converge y que su error es $\sigma/\sqrt{N}$.
6. **Python amplía lo que permite Excel**: el mismo procedimiento se repite miles de veces, para cualquier distribución, con resultados reproducibles y verificación automática contra la teoría.

Referencias

[1] Fernández C., H. *El Teorema del Límite Central*. Guía del curso Estadística para Ingeniería, Facultad de Ingenierías, Universidad de Medellín.

[2] Fernández C., H. *Simulación de Montecarlo* y archivo *Simulación_Montecarlo_40_datos.xlsx*. Guía del curso Estadística para Ingeniería, Universidad de Medellín.

[3] Montgomery, D. C. y Runger, G. C. *Applied Statistics and Probability for Engineers*. Wiley.

[4] Walpole, R. E., Myers, R. H., Myers, S. L. y Ye, K. *Probabilidad y estadística para ingeniería y ciencias*. Pearson.

[5] Ross, S. M. *Simulation*. Academic Press. (Método de la transformada inversa.)

[6] Documentación oficial de NumPy, SciPy, Matplotlib, Plotly y Streamlit.